



北京邮电大学
Beijing University of Posts and Telecommunications

人工智能引论

Artificial Intelligence

计算机学院&信通学院·联合教研团队
北京邮电大学





站在巨人的肩膀上
Standing on Shoulders of Giants

机器学习 之决策树



AI 作画

人工智能 开启通往未来之路的大门

北京邮电大学 ·



目录

CONTNETS

01

分类的概念

02

决策树的基本流程

03

实践一颗决策树

机器学习-监督学习-分类

人工智能

具有人类智力特点的机器



机器学习

从数据中学习
如何完成任务



深度学习

包含多个隐含层
的神经网络结构



强化学习

智能体探索环境状
态、采取行为以及
获得回报的过程




01

PART ONE



监督学习包括回归、分类。




回归




分类



- (1) 垃圾邮件分类
- (2) 图像识别
- (3) 语音识别
- (4) 判断是否患有疾病







决策树

02

PART TWO



决策树的结构


决策树 Decision Tree Based Methods

决策树概念

属性 属性 属性 类别

Tid	Refund	Marital Status	Taxable Income	Cheat
1	Yes	Single	125K	No
2	No	Married	100K	No
3	No	Single	70K	No
4	Yes	Married	120K	No
5	No	Divorced	95K	Yes
6	No	Married	60K	No
7	Yes	Divorced	220K	No
8	No	Single	85K	Yes
9	No	Married	75K	No
10	No	Single	90K	Yes

Training Data




Model: Decision Tree

根节点root node, 内部节点internal node, 叶节点leaf node

决策树 Decision Tree Based Methods

决策树概念

Tid	Refund	categorical		Taxable Income	Cheat
		Marital Status			
1	Yes	Single		125K	No
2	No	Married		100K	No
3	No	Single		70K	No
4	Yes	Married		120K	No
5	No	Divorced		95K	Yes
6	No	Married		60K	No
7	Yes	Divorced		220K	No
8	No	Single		85K	Yes
9	No	Married		75K	No
10	No	Single		90K	Yes



同一数据集可能生成多种决策树

基于决策树的分类方法：基本流程


决策树概念

Tid	Attrib1	Attrib2	Attrib3	Class
1	Yes	Large	125K	No
2	No	Medium	100K	No
3	No	Small	70K	No
4	Yes	Medium	120K	No
5	No	Large	95K	Yes
6	No	Medium	60K	No
7	Yes	Large	220K	No
8	No	Small	85K	Yes
9	No	Medium	75K	No
10	No	Small	90K	Yes

Training Set

Tid	Attrib1	Attrib2	Attrib3	Class
11	No	Small	55K	?
12	Yes	Medium	80K	?
13	Yes	Large	110K	?
14	No	Small	95K	?
15	No	Large	67K	?


Test Set



决策树：基本流程

决策树概念

从根节点出发, 到达叶子节点完成分类.



Test Data


Refund	Marital Status	Taxable Income	Cheat
No	Married	80K	?

决策树：基本流程

决策树概念

Test Data

Refund	Marital Status	Taxable Income	Cheat
No	Married	80K	?




决策树：基本流程

决策树概念

Test Data

Refund	Marital Status	Taxable Income	Cheat
No	Married	80K	?




决策树：基本流程

决策树概念

Test Data

Refund	Marital Status	Taxable Income	Cheat
No	Married	80K	?




决策树：基本流程

决策树概念

Test Data

Refund	Marital Status	Taxable Income	Cheat
No	Married	80K	?




决策树：基本流程

决策树概念

Test Data

Refund	Marital Status	Taxable Income	Cheat
No	Married	80K	?



Assign Cheat to "No"

常用的决策树算法:


- Hunt's Algorithm
- CART
- ID3, C4.5
- SLIQ, SPRINT

Tid	Attrib1	Attrib2	Attrib3	Class
1	Yes	Large	125K	No
2	No	Medium	100K	No
3	No	Small	70K	No
4	Yes	Medium	120K	No
5	No	Large	95K	Yes
6	No	Medium	60K	No
7	Yes	Large	220K	No
8	No	Small	85K	Yes
9	No	Medium	75K	No
10	No	Small	90K	Yes

Training Set

Tid	Attrib1	Attrib2	Attrib3	Class
11	No	Small	55K	?
12	Yes	Medium	80K	?
13	Yes	Large	110K	?
14	No	Small	95K	?
15	No	Large	67K	?

Test Set




决策树的训练过程

决策树训练


- | 设 D_t 训练集的某个子集，用节点 t 表示
- | 生成决策树的基本过程如下：
 - 如果 D_t 中所包含的样本都属于同一类别 y_t ，则节点 t 是标记为类别为 y_t 的叶子节点。
 - 如果 D_t 是空集，则 t 是标记为 y_d 叶子节点。
 - 如果 D_t 所包含的样本属于多个类别，从训练集的属性中挑选一个属性对该子集中的样本进行测试，然后向下划分为若个节点；
 - 递归地，重复上述步骤，直至把训练集中的样本都划归到叶子节点中。

Tid	Refund	Marital Status	Taxable Income	Cheat
1	Yes	Single	125K	No
2	No	Married	100K	No
3	No	Single	70K	No
4	Yes	Married	120K	No
5	No	Divorced	95K	Yes
6	No	Married	60K	No
7	Yes	Divorced	220K	No
8	No	Single	85K	Yes
9	No	Married	75K	No
10	No	Single	90K	Yes



决策树：基本流程

Hunt算法



Tid	Refund	Marital Status	Taxable Income	Cheat
1	Yes	Single	125K	No
2	No	Married	100K	No
3	No	Single	70K	No
4	Yes	Married	120K	No
5	No	Divorced	95K	Yes
6	No	Married	60K	No
7	Yes	Divorced	220K	No
8	No	Single	85K	Yes
9	No	Married	75K	No
10	No	Single	90K	Yes



ID3 算法



- ID3 算法最早是由罗斯昆 (J. Ross Quinlan) 于 1975 年提出的一种决策树构建算法，算法的核心是“**信息熵**”。



- ID3 算法是以信息论为基础，以**信息增益**为衡量标准，从而实现对数据的归纳分类。
- ID3 算法计算每个属性的信息增益，并选取具有最高增益的属性作为给定的测试属性。



信息熵



- 出自 Claude Shannon 的**信息论**（1948年）。
- 证明了熵与信息内容的不确定程度有等价关系。



- 信息熵是**平均信息量**

若一个系统中存在多个事件 $E_1, E_2, \dots, E_n$

每个事件出现的概率是 $p_1, p_2, \dots, p_n$

则这个系统的平均信息量是

$$\text{entropy}(p_1, p_2, \dots, p_n) = -p_1 \log_2 p_1 - p_2 \log_2 p_2 \dots - p_n \log_2 p_n$$



拓展链接

香农与信息熵

信息熵是信息论中最基本、最重要的一个概念，由香农于1948年提出，其表达了信息的“不确定性”（uncertainty）。

熵（entropie，英文为entropy）这一概念最早在热力学领域由德国物理学家克劳修斯于1854年提出。汉语中本无“熵”字，我国物理学家胡刚复教授于1923年首次把entropie译为“熵”。熵在热力学中用来衡量系统的混乱程度，一个系统的混乱度越高，它的熵就越高。

香农将熵这个概念从热力学领域应用于信息领域，其提出的“信息熵”或“香农熵”解决了信息的量化度量问题。一条信息所承载的信息量大小和它的不确定性有直接关系。比如，球队甲和球队乙在历史上进行过多次对决比赛，甲队战胜乙队的胜率为 x ，乙队战胜甲队的胜率为 $1-x$ 。甲、乙两队历史上胜负信息的信息熵为 $-[x\log_2 x + (1-x)\log_2 (1-x)]$ 。在 x 取值为 $\frac{1}{2}$ 时，信息熵取得最大值1。也就是说甲、乙两队势均力敌时，两队对决的胜负不确定性最大，信息熵取值最大。



信息熵



- 例如，有一个 0~9 的数字，0~9 出现的可能性都是 $\frac{1}{10}$ ，那么该数字的信息熵为：

$$entropy(digit) = 10 * (-0.1 * \log_2 0.1) = 3.3$$



- 由于该数字的信息熵为 3.3，因此，至少需要 4 个 bit 才能消除其不确定性。
- 至少需要 4 bits 才能存储10进制中的一位数字。
- 变量的不确定性越大，熵也就越大，需要的信息量也越大，纯度就越小。



信息熵



年龄	收入	学生	信用	买了电脑
<30	高	否	一般	否
<30	高	否	好	否
30-40	高	否	一般	是
>40	中等	否	一般	是
>40	低	是	一般	是
>40	低	是	好	否
30-40	低	是	好	是
<30	中	否	一般	否
<30	低	是	一般	是
>40	中	是	一般	是
<30	中	是	好	是
30-40	中	否	好	是
30-40	高	是	一般	是
>40	中	否	好	否

数量	是	否	信息熵
14	9	5	0.940

entropy(D)

$$= -\frac{9}{14} * \log_2 \frac{9}{14} - \frac{5}{14} * \log_2 \frac{5}{14}$$
$$= 0.940$$



按年龄划分



年龄	收入	学生	信用	买了电脑
<30	高	否	一般	否
<30	高	否	好	否
30-40	高	否	一般	是
>40	中等	否	一般	是
>40	低	是	一般	是
>40	低	是	好	否
30-40	低	是	好	是
<30	中	否	一般	否
<30	低	是	一般	是
>40	中	是	一般	是
<30	中	是	好	是
30-40	中	否	好	是
30-40	高	是	一般	是
>40	中	否	好	否

年龄值	数量	是	否	信息熵
< 30	5	2	3	0.97096
30-40	4	4	0	0
> 40	5	3	2	0.97096

$entropy(< 30)$

$$= -\frac{2}{5} * \log_2 \frac{2}{5} - \frac{3}{5} * \log_2 \frac{3}{5}$$
$$= 0.97096$$

$entropy(30 - 40) = -1 * \log_2 1 = 0$

$entropy(> 40) = 0.97096$



按年龄划分



年龄	收入	学生	信用	买了电脑
<30	高	否	一般	否
<30	高	否	好	否
30-40	高	否	一般	是
>40	中等	否	一般	是
>40	低	是	一般	是
>40	低	是	好	否
30-40	低	是	好	是
<30	中	否	一般	否
<30	低	是	一般	是
>40	中	是	一般	是
<30	中	是	好	是
30-40	中	否	好	是
30-40	高	是	一般	是
>40	中	否	好	否

年龄值	数量	是	否	信息熵
< 30	5	2	3	0.97096
30-40	4	4	0	0
> 40	5	3	2	0.97096
全部	14	9	5	0.694

$$\begin{aligned} & \text{entropy}_{\text{年龄}}(D) \\ &= \frac{5}{14} * \text{entropy}(< 30) \\ &+ \frac{4}{14} * \text{entropy}(30 - 40) \\ &+ \frac{5}{14} * \text{entropy}(> 40) = 0.694 \end{aligned}$$



信息熵比较



数量	是	否	信息熵
14	9	5	0.940

年龄值	数量	是	否	信息熵
< 30	5	2	3	0.97096
30-40	4	4	0	0
> 40	5	3	2	0.97096
全部	14	9	5	0.694

$$\begin{aligned}\Delta_{\text{年龄}} \text{entropy} &= \text{entropy}(D) - \text{entropy}_{\text{年龄}}(D) \\ &= 0.940 - 0.694 \\ &= 0.246\end{aligned}$$

信息增益, Information Gain



按收入划分



年龄	收入	学生	信用	买了电脑
<30	高	否	一般	否
<30	高	否	好	否
30-40	高	否	一般	是
>40	中等	否	一般	是
>40	低	是	一般	是
>40	低	是	好	否
30-40	低	是	好	是
<30	中	否	一般	否
<30	低	是	一般	是
>40	中	是	一般	是
<30	中	是	好	是
30-40	中	否	好	是
30-40	高	是	一般	是
>40	中	否	好	否

收入	数量	是	否	信息熵
高	4	2	2	1
中	6	4	2	0.9183
低	4	3	1	0.8113

$$entropy(\text{高}) = -\frac{2}{4} * \log_2 \frac{2}{4} - \frac{2}{4} * \log_2 \frac{2}{4} = 1$$

$$entropy(\text{中}) = -\frac{4}{6} * \log_2 \frac{4}{6} - \frac{2}{6} * \log_2 \frac{2}{6} = 0.9183$$

$$entropy(\text{低}) = -\frac{3}{4} * \log_2 \frac{3}{4} - \frac{1}{4} * \log_2 \frac{1}{4} = 0.8113$$



按收入划分



年龄	收入	学生	信用	买了电脑
<30	高	否	一般	否
<30	高	否	好	否
30-40	高	否	一般	是
>40	中等	否	一般	是
>40	低	是	一般	是
>40	低	是	好	否
30-40	低	是	好	是
<30	中	否	一般	否
<30	低	是	一般	是
>40	中	是	一般	是
<30	中	是	好	是
30-40	中	否	好	是
30-40	高	是	一般	是
>40	中	否	好	否

收入	数量	是	否	信息熵
高	4	2	2	1
中	6	4	2	0.9183
低	4	3	1	0.8113
全部	14	9	5	0.911

$entropy_{收入}(D)$

$$\begin{aligned} &= \frac{4}{14} * entropy(\text{高}) + \frac{6}{14} * entropy(\text{中}) \\ &\quad + \frac{4}{14} * entropy(\text{低}) \\ &= \frac{4}{14} * 1 + \frac{6}{14} * 0.9183 + \frac{4}{14} * 0.8113 \\ &= 0.911 \end{aligned}$$



按收入划分



数量	是	否	信息熵
14	9	5	0.940

收入	数量	是	否	信息熵
高	4	2	2	1
中	6	4	2	0.9183
低	4	3	1	0.8113
全部	14	9	5	0.911

$$\begin{aligned}\Delta_{\text{收入}} \text{entropy} &= \text{entropy}(D) - \text{entropy}_{\text{收入}}(D) \\ &= 0.940 - 0.911 \\ &= 0.029\end{aligned}$$



按是否学生



年龄	收入	学生	信用	买了电脑
<30	高	否	一般	否
<30	高	否	好	否
30-40	高	否	一般	是
>40	中等	否	一般	是
>40	低	是	一般	是
>40	低	是	好	否
30-40	低	是	好	是
<30	中	否	一般	否
<30	低	是	一般	是
>40	中	是	一般	是
<30	中	是	好	是
30-40	中	否	好	是
30-40	高	是	一般	是
>40	中	否	好	否

学生	数量	是	否	信息熵
是	7	6	1	0.5917
否	7	3	4	0.9852
全部	14	9	5	0.788

$$\begin{aligned}\Delta_{\text{学生}} \text{entropy} &= \text{entropy}(D) - \text{entropy}_{\text{学生}}(D) \\ &= 0.940 - 0.788 \\ &= 0.152\end{aligned}$$



按信用划分



年龄	收入	学生	信用	买了电脑
<30	高	否	一般	否
<30	高	否	好	否
30-40	高	否	一般	是
>40	中等	否	一般	是
>40	低	是	一般	是
>40	低	是	好	否
30-40	低	是	好	是
<30	中	否	一般	否
<30	低	是	一般	是
>40	中	是	一般	是
<30	中	是	好	是
30-40	中	否	好	是
30-40	高	是	一般	是
>40	中	否	好	否

信用	数量	是	否	信息熵
一般	8	6	2	0.8113
好	6	3	3	1
全部	14	9	5	0.892

$$\begin{aligned}\Delta_{\text{信用}} \text{entropy} &= \text{entropy}(D) - \text{entropy}_{\text{信用}}(D) \\ &= 0.940 - 0.892 \\ &= 0.048\end{aligned}$$



信息增益



特征	信息增益
年龄	0.246
收入	0.029
学生	0.152
信用	0.048

算法	支持模型	树结构	特征选择	连续值处理	缺失值处理	剪枝	特征属性多次使用
ID3	分类	多叉树	信息增益	不支持	不支持	不支持	不支持
C4.5	分类	多叉树	信息增益率	支持	支持	支持	不支持
CART	分类 回归	二叉树	基尼基数 均方差	支持	支持	支持	支持

实践一棵决策树

03

PART FOUR





使用鸢尾花数据集，调用Scikit-learn内嵌的决策树分类器构造决策树：

```
from sklearn.datasets import load_iris
from sklearn import tree
iris = load_iris( )
clf = tree.DecisionTreeClassifier( )
clf = clf.fit(iris.data, iris.target)
```



调用Python数据可视化模块graphviz，导出前页构造的决策树，并将结果保存在iris.pdf中。

```
import graphviz

dot_data = tree.export_graphviz(clf, out_file=None,
                                feature_names=iris.feature_names,
                                class_names=iris.target_names,
                                filled=True, rounded=True,
                                special_characters=True)

graph = graphviz.Source(dot_data)
graph.render("iris")
```

所生成的决策树如图所示。



基于鸢尾花数据集生成的决策树



THANKS