



北京邮电大学
Beijing University of Posts and Telecommunications

人工智能引论

Artificial Intelligence

计算机学院&信通学院·联合教研团队
北京邮电大学





AI晓学 | 站在巨人的肩膀上
Standing on Shoulders of Giants

支

持

向

量


机

S

V

M

人工智能 开启通往未来之路的大门





目录

CONTNETS

01 SVM基本概念

02 线性与非线性SVM

03 SVM多分类问题

04 SVM核函数

SVM基本概念

01

PART THREE




什么是支持向量机?

- 一种分类方法
- 适用于二分类
- 可以通过多个支持向量机的组合实现多分类

向量空间模型进行分类


- 在向量空间的分类中，我们必须要做的工作是定义类别之间的边界，从而得到分类的结果。




SVM基本概念

寻找最大间隔

■ SVM寻找区分两类的超平面, 使边际(margin)最大。



支持向量与支持向量机



a、b、c、d、e称作支持向量，唯一决定了最优分界面。这样得到的二分类器称作支持向量机。

训练集T

$$T = \{(x_1, y_1), (x_2, y_2), \dots, (x_N, y_N)\}$$

- 样本: $x_i = (x_i^{(1)}, x_i^{(2)}, \dots, x_i^{(n)})$
- 标记: $y_i \in \{-1, +1\}$

最优分界面方程

$$w^* \cdot x + b^* = 0$$

- 其中 w^* 、 x 是向量, b^* 是标量:

$$w^* = (w_1^*, w_2^*, \dots, w_n^*)$$

$$x = (x^{(1)}, x^{(2)}, \dots, x^{(n)})$$

SVM基本概念




北京邮电大学
Beijing University of Posts and Telecommunications

决策函数


$$f(x) = \text{sign}(w^* \cdot x + b^*)$$

$$f(x) = \begin{cases} +1, & \text{正类} \\ -1, & \text{负类} \end{cases}$$



SVM基本概念

样本 x_i 到超平面 (w, b) 的函数间隔



$$\hat{y}_i = y_i \cdot (w \cdot x_i + b)$$

几何间隔

- 归一化的函数间隔

$$\gamma_i = y_i \cdot \left(\frac{w}{\|w\|} \cdot x_i + \frac{b}{\|w\|} \right)$$

$$\|w\| = \sqrt{w_1^2 + w_2^2 + \cdots + w_n^2}$$

- ◆ 实质就是点到平面的欧氏距离

线性与非线性SVM

02

PART THREE

线性与非线性SVM



北京邮电大学
Beijing University of Posts and Telecommunications

支持向量机的分类


- 线性可分支持向量机
- 线性支持向量机
- 非线性支持向量机

线性与非线性SVM




北京邮电大学
Beijing University of Posts and Telecommunications

线性可分支持向量机




线性可分支持向量机



线性与非线性SVM

线性可分支持向量机



$$\min_{w,b} \frac{1}{2} \|w\|^2$$

$$s.t. y_i \cdot (w \cdot x_i + b) \geq 1 \quad i = 1, 2, \dots, N$$


$$\min_{w,b} \left(\frac{1}{2} \|w\|^2 + C \cdot \sum_{i=1}^N \xi_i \right)$$

$$s.t. y_i \cdot (w \cdot x_i + b) \geq 1 - \xi_i \quad i = 1, 2, \dots, N$$

$$\xi_i \geq 0 \quad i = 1, 2, \dots, N$$

线性与非线性SVM

线性支持向量机



$\alpha = C$ 时 $\xi \neq 0$

$$\min_{w,b} \left(\frac{1}{2} \|w\|^2 + C \cdot \sum_{i=1}^N \xi_i \right)$$

$$s.t. \ y_i \cdot (w \cdot x_i + b) \geq 1 - \xi_i$$

$$\xi_i \geq 1 - y_i \cdot (w \cdot x_i + b)$$


$$\xi_i = 1 - y_i \cdot (w \cdot x_i + b)$$

线性与非线性SVM



北京邮电大学
Beijing University of Posts and Telecommunications

非线性支持向量机



非线性支持向量机

◆ 思路：能否通过一个变换，将非线性支持向量机转化为线性的呢？

◆ 前面的例子

□ 原始空间


$$x = (x^{(1)}, x^{(2)})$$

□ 变换后的空间

$$z = (z^{(1)}, z^{(2)})$$

□ 变换 $\phi(x)$

$$z = \phi(x) = \left((x^{(1)})^2, (x^{(2)})^2 \right)$$



线性与非线性SVM


非线性支持向量机

- ◆ 原空间的椭圆方程

$$w_1(x^{(1)})^2 + w_2(x^{(2)})^2 + b = 0$$

- ◆ 变换后的空间成为平面方程


$$w_1z^{(1)} + w_2z^{(2)} + b = 0$$



线性与非线性SVM

举例

◆ 设 $x_1=(0,0)$ 、 $x_2=(1,1)$ 属于正类， $x_3=(1,0)$ ， $x_4=(0,1)$ 属于负类




线性与非线性SVM




北京邮电大学
Beijing University of Posts and Telecommunications

举例



$$\begin{aligned}x_1 &= (0, 0) \\x_2 &= (1, 1) \\x_3 &= (1, 0) \\x_4 &= (0, 1)\end{aligned}$$



$$\begin{aligned}z_1 &= (0, 0, 0) \\z_2 &= (1, \sqrt{2}, 1) \\z_3 &= (1, 0, 0) \\z_4 &= (0, 0, 1)\end{aligned}$$

SVM多分类问题

03

PART THREE

SVM多分类问题

支持向量机用于多分类问题

■ 一对一法

- 设有 K 个类别，任意两个类别构建一个支持向量机
- 共有 $K(K - 1)/2$ 个支持向量机
- 采用投票法对待分类样本分类


SVM多分类问题



北京邮电大学
Beijing University of Posts and Telecommunications

支持向量机用于多分类问题

■ 一对一法





★ 类2得1票、类3的2票

★ 类2得2票、类3的1票

类2、类3分类器

SVM多分类问题

支持向量机用于多分类问题



SVM多分类问题

支持向量机用于多分类问题

■ 一对一法的特点

◆ 性能比较好

- 多分类器投票

◆ 效率比较低

- 分类器数量比较多
- $K(K - 1)/2$ 个分类器
 - 10个类别时: $10 \times (10 - 1) / 2 = 45$
 - 100个类别时: $100 \times (100 - 1) / 2 = 4950$



SVM多分类问题

支持向量机用于多分类问题

■ 一对多法

- K个类别，每个类别做正类，其余K-1个类别合并在一起做负类，共构建K个支持向量机

红色：正
蓝色：负



SVM多分类问题

支持向量机用于多分类问题

■ 一对多法的特点


- ◆ 比较少的分类器
 - $K (> 3)$ 个类别, K 个分类器
- ◆ 样本不平衡问题
 - 正类少, 负类多
- ◆ 解决方法
 - 对正负两类样本设置不同的参数 C

SVM多分类问题

支持向量机用于多分类问题

■ 层次法

- 从根节点开始，每次划分为两个类别




SVM多分类问题

支持向量机用于多分类问题

■ 层次法的特点

- ◆ 效率比较高
 - 构建 $K-1$ 个分类器
 - 分类时使用约 $\log_2 K$ 个
- ◆ 错误累积
 - 前面的错误后面无法补救



SVM核函数

04

PART THREE



定义

- 如果函数 $K(x_i, x_j) = \phi(x_i) \cdot \phi(x_j)$, 则称 $K(x_i, x_j)$ 为核函数。

核函数的作用

- 将低维空间中线性不可分的数据映射到高维空间, 使其在高维空间中变得线性可分, 以便使用线性分类器来解决非线性问题, 避免在高维空间中直接进行复杂的计算。

核方法求解非线性支持向量机

- ◆ 通过核函数在原空间计算变换后空间的点积
- ◆ 不需要知道变换函数

$$K(x_i, x_j) = \phi(x_i) \cdot \phi(x_j)$$

- ◆ 非线性支持向量机

$$\begin{aligned} \min_{\alpha} & \left(\frac{1}{2} \sum_{i=1}^N \sum_{j=1}^N \alpha_i \alpha_j y_i y_j \left(\phi(x_i) \cdot \phi(x_j) \right) - \sum_{i=1}^N \alpha_i \right) \\ \text{s.t.} & \sum_{i=1}^N \alpha_i y_i = 0 \\ & 0 \leq \alpha_i \leq C, \quad i = 1, 2, \dots, N \end{aligned}$$

Diagrammatic annotation: A red dashed oval encircles the term $\phi(x_i) \cdot \phi(x_j)$ in the objective function, with a red arrow pointing to it from the label $K(x_i, x_j)$ written in red above the oval.

常用核函数

◆ 多项式核函数

$$K(x, y) = (x \cdot y + 1)^d$$

◆ 最优分界超曲面方程

$$\sum_{i=1}^N \alpha_i^* y_i (x \cdot x_i + 1)^d + b^* = 0$$

$$b^* = y_j - \sum_{i=1}^N \alpha_i^* y_i (x \cdot x_i + 1)^d$$

◆ 分类决策函数

$$f(x) = \text{sign} \left(\sum_{i=1}^N \alpha_i^* y_i (x \cdot x_i + 1)^d + b^* \right)$$

常用核函数

◆ 高斯核函数

$$K(x, y) = e^{\left(-\frac{\|x-y\|^2}{2\sigma^2}\right)}$$

◆ 最优分界超曲面方程

$$\sum_{i=1}^N \alpha_i^* y_i e^{\left(-\frac{\|x-x_i\|^2}{2\sigma^2}\right)} + b^* = 0$$
$$b^* = y_j - \sum_{i=1}^N \alpha_i^* y_i e^{\left(-\frac{\|x_i-x_j\|^2}{2\sigma^2}\right)}$$

◆ 分类决策函数

$$f(x) = \text{sign} \left(\sum_{i=1}^N \alpha_i^* y_i e^{\left(-\frac{\|x-x_i\|^2}{2\sigma^2}\right)} + b^* \right)$$

常用核函数

◆ sigmoid核函数

$$K(x, y) = \tanh(\gamma(x \cdot y) + r)$$

◆ 最优分界超曲面方程

$$\sum_{i=1}^N \alpha_i^* y_i \tanh(\gamma(x \cdot x_i) + r) + b^* = 0$$

$$b^* = y_j - \sum_{i=1}^N \alpha_i^* y_i \tanh(\gamma(x_i \cdot x_j) + r)$$

◆ 分类决策函数

$$f(x) = \text{sign} \left(\sum_{i=1}^N \alpha_i^* y_i \tanh(\gamma(x \cdot x_i) + r) + b^* \right)$$

优点

- 能有效处理高维空间，即使在维度远大于样本数的情况下也能够有效工作。
- 可以处理复杂的非线性问题。
- 最小化结构风险而不是经验风险，因此算法泛化能力强。
- 通过调整不同的核函数和参数，可以适应多种应用场景。

缺点

- 计算成本高，特别是在大规模数据集上，训练时间较长，内存消耗大。
- 需要花费大量时间进行参数调优，如选择合适的核函数、调节正则化参数等。
- 对于异常值比较敏感，可能会影响模型的整体性能。

作业题

题1

■在支持向量机中，哪些样本被称为支持向量？它们起什么作用？

题2

■在支持向量机中，间隔是如何定义的？最大间隔的几何意义是什么？

题3

■简述SVM中核函数的作用，并列举出常见的核函数。