



北京邮电大学
Beijing University of Posts and Telecommunications

人工智能引论

Artificial Intelligence

计算机学院&信通学院·联合教研团队
北京邮电大学





AI 晓学 | 站在巨人的肩膀上
Standing on Shoulders of Giants

深

度

学


习

常

见

模

型



人工智能 开启通往未来之路的大门

北京邮电大学 · 计算机学院



目录

CONTNETS

01 深度学习的常用架构

02 深度学习——卷积神经网络

03 典型应用案例

深度学习常用架构

01

PART TWO




深度学习和机器学习、神经网络的区别



北京邮电大学
Beijing University of Posts and Telecommunications

深度学习——深度学习的概念源于人工神经网络。

含多隐层的多层感知器就是一种深度学习结构。深度学习通过组合低层特征形成更加抽象的高层表示属性类别或特征，以发现数据的分布式特征表示。



➤ 归属关系

- 机器学习的一个子集
- 是一个多层神经网络





➤ 自动学习能力

- 深度学习 > 神经网络 > 机器学习

深度学习常见模型



北京邮电大学
Beijing University of Posts and Telecommunications



1998

2012

2014


2015

2017


2018

2020


CNN (LeNet-5)




VGGNet





ResNet



Transformer



VIT




深度学习常见模型



北京邮电大学
Beijing University of Posts and Telecommunications


卷积神经网络阶段



深度学习常见模型




北京邮电大学
Beijing University of Posts and Telecommunications



深度学习常见模型



北京邮电大学
Beijing University of Posts and Telecommunications



深度学习示例



北京邮电大学
Beijing University of Posts and Telecommunications

看图作文

用户_SXn6r0

详细地描述这张图片，包括每一个细节



ChatGLM AI

这是一张火箭发射的图片。

1. 图片中间是一枚正在点火的火箭，火箭顶部的四个发动机喷出橙色的火焰。
2. 火箭周围是发射塔架，发射塔架由金属结构组成，看起来非常坚固。
3. 火箭底部冒出白色的烟雾。
4. 背景是深蓝色的天空。




深度学习示例

深度学习怎么做到“看图作文”？




无所不能的大模型

看图作文



卷积神经网络模型

生成文字



Transformer 序列模型

- 神经网络能够学习和表示复杂数据结构和模式
- 神经网络如何学习图像的特征、文字（语言）的特征？

深度学习

-卷积神经网络

02

PART TWO



卷积神经网络的结构




北京邮电大学
Beijing University of Posts and Telecommunications

卷积神经网络（Convolutional Neural Networks, CNN）

- 是一种前馈神经网络
- 对于大型图像处理有出色表现

CONV——卷积层
RELU——激活层
POOL——池化层
FC——全连接层



卷积神经网络基础

核心组件=卷积层+池化层+激活函数+全连接层与输出层

卷积层

通过滑动滤波器在输入数据上提取局部特征。

特点：

局部感受野
权值共享
平移不变性

池化层

用于对特征图进行下采样，降低数据维度。

特点：

降维
减少参数量
防止过拟合

激活函数

引入非线性，使网络能够学习复杂的模式。

特点：

解决梯度消失
加速训练

全连接层

将提取的特征映射到最终的输出空间。

特点：

特征整合
分类/回归

卷积神经网络基础

核心组件=卷积层+池化层+激活函数+全连接层与输出层

卷积层

通过滑动滤波器在输入数据上提取局部特征。

特点：

局部感受野
权值共享
平移不变性

池化层

用于对特征图进行下采样，降低数据维度。

特点：

降维
减少参数量
防止过拟合

激活函数

引入非线性，使网络能够学习复杂的模式。

特点：

解决梯度消失
加速训练

全连接层

将提取的特征映射到最终的输出空间。


特点：

特征整合
分类/回归

卷积层



卷积层(卷积操作)-提取图像局部特征



卷积层

卷积操作的计算——滤波器的滑动操作

1	1	1	1
1	1	0	1
1	0	1	0
0	1	0	1

*

1	0	1
0	1	0
1	0	1

=

5	2
1	5

$$\begin{aligned} f_{0,0} = & x_{00}w_{00} + x_{01}w_{01} + x_{02}w_{02} \\ & + x_{10}w_{10} + x_{11}w_{11} + x_{12}w_{12} \\ & + x_{20}w_{20} + x_{21}w_{21} + x_{22}w_{2,2} \end{aligned}$$

x_{00}	x_{01}	x_{02}	x_{03}
x_{10}	x_{11}	x_{12}	x_{13}
x_{20}	x_{21}	x_{22}	x_{23}
x_{30}	x_{31}	x_{32}	x_{33}

*

w_{00}	w_{01}	w_{02}
w_{10}	w_{11}	w_{12}
w_{20}	w_{21}	w_{22}

=

f_{00}	f_{01}
f_{10}	f_{11}

$x_{i,j}$ 表示 输入图 的第 i 行第 j 列元素

$w_{m,n}$ 表示 卷积核 的第 m 行第 n 列元素

$f_{i,j}$ 表示 输出特征图 的第 i 行第 j 列元素

输入图像

卷积核


输出特征

卷积层



北京邮电大学
Beijing University of Posts and Telecommunications

卷积操作的计算——滤波器的滑动操作



卷积层



卷积操作的计算过程

输入

2	1	0	2	3
9	5	4	2	0
2	3	4	5	6
1	2	3	1	0
0	4	4	2	8

权重 (模式)

-1	0	1
-1	0	1
-1	0	1

输出 (匹配结果)

-5	0	1
-1	-2	-5
8	-1	3

$$\begin{aligned} & (-1) \times 2 + 0 \times 1 + 1 \times 0 \\ & + (-1) \times 9 + 0 \times 5 + 1 \times 4 \\ & + (-1) \times 2 + 0 \times 3 + 1 \times 4 = -5 \end{aligned}$$

卷积层



卷积操作的计算过程

输入

2	1	0	2	3
9	5	4	2	0
2	3	4	5	6
1	2	3	1	0
0	4	4	2	8

权重 (模式)

-1	0	1
-1	0	1
-1	0	1

输出 (匹配结果)

-5	0	1
-1	-2	-5
8	-1	3

卷积层



卷积操作的计算过程

输入

2	1	0	2	3
9	5	4	2	0
2	3	4	5	6
1	2	3	1	0
0	4	4	2	8

权重 (模式)

-1	0	1
-1	0	1
-1	0	1

输出 (匹配结果)

-5	0	1
-1	-2	-5
8	-1	3

卷积层



北京邮电大学
Beijing University of Posts and Telecommunications

卷积操作的计算过程

输入

2	1	0	2	3
9	5	4	2	0
2	3	4	5	6
1	2	3	1	0
0	4	4	2	8

权重 (模式)

-1	0	1
-1	0	1
-1	0	1

卷积核
训练获得

卷积神经网络

- 局部连接
- 权值共享

输出 (匹配结果)

-5	0	1
-1	-2	-5
8	-1	3


卷积核



北京邮电大学
Beijing University of Posts and Telecommunications

卷积核尺寸

- 小卷积核：细粒度特征
- 大卷积核：大粒度特征
- 对于二维输入，一般是 3×3 、 5×5 、 $7 \times 7 \dots$




卷积核



北京邮电大学
Beijing University of Posts and Telecommunications

- 步长
 - 卷积核每次移动的距离
- 步长是可以设定的
 - 以2为例



卷积步长：卷积核可以按照指定的间隔进行卷积操作，这个间隔就是卷积步长

典型的卷积

- 原始卷积 (Vanilla Convolution)
- 空洞卷积 (Atrous convolution)
- 可变形卷积 (Deformable convolution)
- 组卷积 (Group convolution)
- 转置卷积 (Transposed Convolution)
- 深度可分离卷积 (Depthwise Separable Convolution)
-

卷积模板



北京邮电大学
Beijing University of Posts and Telecommunications

原始卷积

1 _{x1}	1 _{x0}	1 _{x1}	0	0
0 _{x0}	1 _{x1}	1 _{x0}	1	0
0 _{x1}	0 _{x0}	1 _{x1}	1	1
0	0	1	1	0
0	1	1	0	0

Image


4		

Convolved
Feature

作用：

- 提取局部特征
- 参数共享


空洞卷积



作用：

- 扩大感受野，
- 不增加参数量

可变形卷积



(a)

(b)

作用：


- 通过增加额外的偏移量来增强模型对几何变换的适应性

卷积模板



北京邮电大学
Beijing University of Posts and Telecommunications


分组卷积



作用：

- 提取局部特征
- 参数共享


转置卷积



作用：

- 扩大感受野，
- 不增加参数量

1*1 卷积



作用：



- 通过增加额外的偏移量来增强模型对几何变换的适应性

卷积模板



北京邮电大学
Beijing University of Posts and Telecommunications

转置卷积，即反卷积




作用：特征可视化

卷积模板



北京邮电大学
Beijing University of Posts and Telecommunications

深度可分离卷积



作用：减少模型参数，加速计算

卷积神经网络基础

核心组件=卷积层+池化层+激活函数+全连接层与输出层

卷积层

通过滑动滤波器在输入数据上提取局部特征。

特点：

局部感受野
权值共享
平移不变性

池化层

用于对特征图进行下采样，降低数据维度。

特点：

降维
减少参数量
防止过拟合

激活函数

引入非线性，使网络能够学习复杂的模式。

特点：

解决梯度消失
加速训练

全连接层



将提取的特征映射到最终的输出空间。

特点：

特征整合
分类/回归

池化层

手写体



交叉特征

241	0	0	0	241
229	241	242	242	243
0	240	242	242	0
242	242	237	241	0
0	0	0	0	242

230	0	0	0	240
0	205	232	240	27
0	0	236	0	0
225	219	238	237	0
0	0	0	239	0

卷积核

1	-1	-1	-1	1
-1	1	-1	1	-1
-1	-1	1	-1	-1
-1	1	-1	1	-1
1	-1	-1	-1	1

1	-1	-1	-1	1
-1	1	-1	1	-1
-1	-1	1	-1	-1
-1	1	-1	1	-1
1	-1	-1	-1	1

卷积结果

241	0	0	0	241
-229	241	-242	242	-243
0	-240	242	-242	0
-242	242	-237	241	0
0	0	0	0	242

230	0	0	0	240
0	205	-232	240	-27
0	0	236	0	0
-225	219	-238	237	0
0	0	0	-239	0

结果：646

结果：257


计算机如何突出千奇百怪的数字的特征？

池化层

最大池化

在给定的池化窗口，将窗口中的**最大值**作为输出，保留了**最显著特征**，边缘和高亮区域更加突出，特点是更好的**提取纹理信息**

实现下采样
减少参数量



平均池化

在给定的池化窗口内，将窗口中所有值的**平均值**作为输出，相比最大池化**更加平滑**，能够**保留更多细节信息**

实现下采样
减少参数量

1	2	3	3
1	8	5	4
0	9	2	2
2	7	3	4

3	3.75
4.5	2.75

卷积神经网络基础

核心组件=卷积层+池化层+激活函数+全连接层与输出层

卷积层

通过滑动滤波器在输入数据上提取局部特征。

特点：

局部感受野
权值共享
平移不变性

池化层

用于对特征图进行下采样，降低数据维度。

特点：

降维
减少参数量
防止过拟合

激活函数

引入非线性，使网络能够学习复杂的模式。

特点：

解决梯度消失
加速训练

全连接层

将提取的特征映射到最终的输出空间。

特点：

特征整合
分类/回归

激活函数



北京邮电大学
Beijing University of Posts and Telecommunications


Sigmoid函数

表达式： $S(x) = \frac{1}{1 + e^{-x}}$

特点：

函数值在 0 到 1 之间，具有平滑的曲线，能够将任何实数映射到这个区间，可用于表示概率或进行二分类任务。

$$S(x) = \frac{1}{1 + e^{-x}}$$



缺点： 存在梯度消失问题

应用场景： 早期常用于二分类问题的输出层，如判断图像是否属于某一类。

激活函数



北京邮电大学
Beijing University of Posts and Telecommunications

Tanh函数


表达式： $\text{Tanh}(x) = \frac{e^x - e^{-x}}{e^x + e^{-x}}$

特点：

函数值范围在 -1 到 1 之间，是以 0 为中心的，相比 sigmoid 函数，在一些情况下能使训练更稳定、收敛速度更快。

缺点： 存在梯度消失问题

应用场景： 在处理需要正负值输出的任务时表现较好，如语音识别等领域。



激活函数



北京邮电大学
Beijing University of Posts and Telecommunications

ReLU函数


表达式： $\text{ReLU}(x) = \max(0, x)$

特点：

计算非常简单高效,在训练过程中能够有效缓解梯度消失问题,使神经网络能够更快地收敛,大大提高了训练速度。

缺点： 存在 Dead ReLU 问题

应用场景： 是目前卷积神经网络中最常用的激活函数，适用于图像、语音等多种数据的处理任务。。



激活函数

Leaky ReLU函数


表达式： $\text{LeakyReLU}(x) = \begin{cases} x, & x > 0 \\ \alpha x, & x \leq 0 \end{cases}$

特点：


在一定程度上解决了 ReLU 的 Dead ReLU 问题,使得在反向传播过程中仍有梯度通过,有助于网络的训练。

缺点： 不同的 α 值可能会对模型性能产生不同的影响

应用场景： 在一些对 ReLU 效果不满意,容易出现 Dead ReLU 问题的场景中



ReLU



vs

Leaky ReLU

激活函数

PReLU函数



表达式：
$$\text{PReLU}(x) = \begin{cases} x, & x > 0 \\ \alpha x, & x \leq 0 \end{cases}$$

特点：

相比 Leaky ReLU, PReLU 能够自适应地学习不同神经元的负斜率,进一步提高了模型的性能和泛化能力。

缺点： 增加了模型的参数数量和训练的复杂性,需要更多的计算资源和时间。

应用场景： 在一些对模型性能要求较高、数据复杂的场景中表现较好,如大规模图像分类、目标检测等任务。



激活函数


ELU函数

表达式：

$$ELU(x) = \begin{cases} x, & x > 0 \\ \alpha(e^x - 1), & x \leq 0 \end{cases}$$

特点：

输出均值接近 0，有助于使网络的训练更加稳定。



缺点： 计算相对复杂，需要计算指数函数，相比 ReLU 等函数计算成本较高。

应用场景： 在一些需要更好的训练稳定性和模型性能的场景中使用，如在一些对模型精度要求较高的图像和语音处理任务中可能会有较好的表现。

激活函数

Swish函数


表达式： $Swish(x) = x \cdot sigmoid(\beta x)$

特点：

具有平滑、非单调的特性，在不同的输入范围内表现出不同的非线性行为，能够更好地拟合数据的复杂分布。

缺点： 计算相对复杂，包含了乘法和 sigmoid 函数的计算，会增加一定的计算量。

应用场景： 在一些对模型的非线性表达能力要求较高的场景中表现出色，如自然语言处理、图像生成等任务中，近年来受到了越来越多的关注和应用。



卷积神经网络基础

核心组件=卷积层+池化层+激活函数+全连接层与输出层

卷积层

通过滑动滤波器在输入数据上提取局部特征。

特点：

局部感受野
权值共享
平移不变性

池化层

用于对特征图进行下采样，降低数据维度。

特点：

降维
减少参数量
防止过拟合

激活函数

引入非线性，使网络能够学习复杂的模式。

特点：

解决梯度消失
加速训练

全连接层

将提取的特征映射到最终的输出空间。

特点：

特征整合
分类/回归

深度学习中存在的主要几个问题



北京邮电大学
Beijing University of Posts and Telecommunications

数据依赖问题

- 数据质量敏感
- 数据需求量大

解决方案

01

- 数据增强-旋转、缩放等方式
- 自监督学习-不依赖人工标注

过拟合

- 训练数据有限
- 模型过于复杂

解决方案

02

- 扩充数据量
- 增加正则项、降低模型复杂度
- 早退

梯度问题

- 梯度消失
- 梯度爆炸

解决方案

03

- 权重初始化
- 残差连接
- 梯度裁剪等

深度学习中存在的主要几个问题

模型复杂问题

- 参数量爆炸
- 硬件资源受限
- 训练能耗高

解决方案

01

- 模型压缩
- 轻量化架构
- 分布式训练

可解释性

- 黑箱模型
- 高风险领域应用受限

解决方案

02

- 可解释模型
- 可视化工具，如 Grad-CAM

对抗样本

- 微小扰动错误检测
- 安全场景风险大

解决方案

03


- 对抗训练
- 鲁棒性评估

深度学习模型示例详解-ResNet



北京邮电大学
Beijing University of Posts and Telecommunications

思考：持续向一个“基础”的卷积神经网络上面叠加更深的层数会发生什么？



问题：网络越深错误率越大？ Why？

猜测：过拟合？
梯度消失？
梯度爆炸？



深度学习模型示例详解-ResNet



北京邮电大学
Beijing University of Posts and Telecommunications

- 残差网络（ResNet）背后两位杰出的中国科学家



孙剑（1976-2022）



何凯明（1984-）

深度学习模型示例详解-ResNet



- 孙剑（1976-2022）旷视首席科学家、旷视研究院院长
 - 2015年带领何恺明等人开发世界上第一个上百层的深度神经网络——“深度残差网络（ResNet）”
 - 2016年拿下了计算机视觉顶级会议CVPR的最佳论文奖，迄今引用量已超过12万

Deep Residual Learning for Image Recognition

Kaiming He Xiangyu Zhang Shaoqing Ren Jian Sun
Microsoft Research
{kahe, v-xiangz, v-shren, jiansun}@microsoft.com

Abstract

Deeper neural networks are more difficult to train. We present a residual learning framework to ease the training of networks that are substantially deeper than those used previously. We explicitly reformulate the layers as learning residual functions with reference to the layer inputs, instead of learning unreferenced functions. We provide comprehensive empirical evidence showing that these residual networks are easier to optimize, and can gain accuracy from considerably increased depth. On the ImageNet dataset we




Figure 1. Training error (left) and test error (right) on CIFAR-10 with 20-layer and 56-layer “plain” networks. The deeper network has higher training error, and thus test error. Similar phenomena on ImageNet is presented in Fig. 4.

Google Scholar



Jian Sun

Chief Scientist of Megvii, Managing Director of Megvii Research
Verified email at megvii.com - [Homepage](#)
[Computer Vision](#) [Deep Learning](#) [Computer Graphics](#)

FOLLOW

TITLE

Deep residual learning for image recognition
K He, X Zhang, S Ren, J Sun

CITED BY

255757

YEAR

2016

CVI 10 Dec 2015

ResNet：深度残差网络

ResNet Google Scholar引用

深度学习模型示例详解-ResNet



- 何凯明（1984-）人工智能科学家，麻省理工学院电气工程与计算机科学系副教授
 - 2009年成为CVPR最佳论文首位华人得主
 - 2015年第一个上百层的深度神经网络——“深度残差网络（ResNet）”主要开发者

Deep Residual Learning for Image Recognition

Kaiming He Xiangyu Zhang Shaoqing Ren Jian Sun
Microsoft Research
{kahe, v-xiangz, v-shren, jiansun}@microsoft.com

Abstract

Deeper neural networks are more difficult to train. We present a residual learning framework to ease the training of networks that are substantially deeper than those used previously. We explicitly reformulate the layers as learning residual functions with reference to the layer inputs, instead of learning unreferenced functions. We provide comprehensive empirical evidence showing that these residual networks are easier to optimize, and can gain accuracy from considerably increased depth. On the ImageNet dataset we




Figure 1. Training error (left) and test error (right) on CIFAR-10 with 20-layer and 56-layer “plain” networks. The deeper network has higher training error, and thus test error. Similar phenomena on ImageNet is presented in Fig. 4.

Google Scholar



Kaiming He

Associate Professor, EECS, MIT
Verified email at mit.edu - [Homepage](#)
[Computer Vision](#) [Machine Learning](#)

FOLLOW

TITLE

CITED BY

YEAR

Deep Residual Learning for Image Recognition

K He, X Zhang, S Ren, J Sun

Computer Vision and Pattern Recognition (CVPR), 2016

261379

2016


CVI 10 Dec 2015

ResNet：深度残差网络

ResNet Google Scholar引用

深度学习模型示例详解-ResNet

ImageNet大赛历年冠军



如何做到网络深度增加，性能越来越好？




深度学习模型示例详解-ResNet



北京邮电大学
Beijing University of Posts and Telecommunications


残差学习

引入残差块，解决深层网络训练时的梯度消失和梯度爆炸问题，使网络能够更有效地学习恒等映射。





瓶颈结构

采用1x1卷积对输入进行降维，再通过3x3卷积进行特征提取，最后通过1x1卷积进行升维，有效减少计算量和参数数量。



短路连接

在残差块中，输入和输出之间进行直接的短路连接，使得信息能够直接传播到深层，增强网络特征提取能力。



深度学习模型示例详解-ResNet


ResNet核心思想

ResNet通过堆叠**残差模块**以构建任意深度的神经网络，而不会出现“退化”现象。

ResNet可分解为：

$$H(x) = F(x) + x$$

其中， $F(x)$ 是残差函数，表示输入 x 与输出 $H(x)$ 之间的残差。通过这种方式，网络只需要学习残差 $F(x)$ ，而不是直接学习映射 $H(x)$ 。



残差模块

深度学习模型示例详解-ResNet


ResNet贡献

- 如果恒等映射是最优的，那么将权重设为 0 会很容易

理想情况下，如果 $H(x) = x$ ，也就是恒等映射是最优的，那么残差 $F(x) = 0$

- 如果最优映射更接近恒等映射，就更容易找到微小的波动。

实际上， $H(x) \neq x$ ，但可能非常接近，那么意味着残差 $F(x) = H(x) - x$ 的值相对较小，网络只需要学习这些微小的波动，能够支持训练极深的网络。





残差模块

深度学习模型示例详解-ResNet



北京邮电大学
Beijing University of Posts and Telecommunications

ResNet—CIFAR-10分类结果





结论： 深度ResNet训练过程是随着网络的深度增加，分类性能增加

深度学习模型示例详解-ResNet



北京邮电大学
Beijing University of Posts and Telecommunications

ResNet—ImageNet分类结果



结论： 深度ResNet训练过程是随着网络的深度增加，分类性能增加

深度学习模型示例详解-ResNet




北京邮电大学
Beijing University of Posts and Telecommunications

ResNet—ImageNet分类结果

时间复杂度:

ResNet-152 < VGG-16/19



10-crop testing, top-5 val error(%)

结论：网络越深，分类误差越小

课后作业：基于CNN的LeNet手写字体识别




北京邮电大学
Beijing University of Posts and Telecommunications



MNIST数据集：

- 是一个广泛使用的手写数字识别数据集，由美国国家标准与技术研究所（National Institute of Standards and Technology, NIST）整理而成；
- 包含了来自250个不同人手写的数字图片，其中一半是高中生，另一半来自人口普查局的工作人员；
- 分为训练集和测试集，训练集包含60,000张图片，测试集包含10,000张图片；
- 每张图片的大小为 28×28 像素，图片中的数字以黑底白字的形式呈现，黑色背景用0表示，白色数字用0到1之间的浮点数表示，数字越接近1，颜色越白。图片的标签则以一维数组的形式给出，采用one-hot编码，例如数字5的标签表示为 $[0,0,0,0,0,1,0,0,0,0]$ 。

计算机读入
图片可视化



课后作业：基于CNN的LeNet手写字体识别



北京邮电大学
Beijing University of Posts and Telecommunications

作业步骤：

1. 数据准备：加载MNIST数据集
将像素值归一化到[0,1]区间
2. 构建CNN模型，模型需包含至少：2个卷积层，2个池化层，1个全连接输出层，
可自行添加其他层（如Dropout、BatchNorm等）
3. 模型训练：选择合适的损失函数和优化器，设置合理的批量大小和训练轮次，
记录训练过程中的损失和准确率变化
4. 模型评估：在测试集上计算最终准确率，可视化至少5个错误分类样本