

# 强化学习核心技术：蒙特卡洛方法与 Actor-Critic模型(DDPG)

——以 AlphaGo 为例，探索AI的决策奥秘



北京邮电大学  
Beijing University of Posts and Telecommunications



# 目录

1

蒙特卡洛方法

2

Actor-Critic 模型

3

案例：AlphaGo

# Part 1



## 蒙特卡洛方法



# 蒙特卡洛方法

蒙特卡洛方法：“多次试验，平均评估”



蒙特卡洛方法的核心思想非常简单但强大：当我们想知道某件事的平均结果或期望值，但又很难直接计算时，我们可以通过多次随机试验来模拟这件事，然后统计和平均实验结果，从而估计出我们想要的值。简单来说，就是“用实验说话”。

## 生活例子：估算罐子里有多少豆子

### 实验与探究：

瓶子里有多少粒豆子



假设你想估算一个罐子里有多少豆子，但不能打开罐子数。蒙特卡洛方法可以这样做：

1. 随机抓取罐子里的一小把豆子。
2. 数一数抓取的豆子数量。
3. 多次重复步骤 1 和 2。
4. 计算多次抓取豆子数量的平均值。
5. 这个平均值就可以近似代表罐子里豆子的平均密度，再结合罐子体积，就能估算出罐子里豆子的大概总数。

## 蒙特卡洛方法在强化学习中的应用：价值评估

在强化学习中，蒙特卡洛方法主要用来做**价值评估**(Value Estimation)。我们要评估一个**状态**(State) 的 “好坏程度”，也就是**价值**(Value)。

**价值函数**(Value Function)  $V(s)$ ：代表从状态 $s$ 开始，未来能获得的**平均累积奖励**的**期望值**。价值越高，状态越“好”。蒙特卡洛方法就是用来估计这个 $V(s)$ 的。

## Episode (回合) 与 Return (回报)

为了理解蒙特卡洛价值评估，我们需要先回顾两个概念：

- **Episode (回合)**: 智能体与环境的一次完整交互过程，从初始状态开始，到终止状态结束。就像玩一局游戏。
- **Return (回报)  $G_t$** : 在一个 Episode 中，智能体从某个时间步  $t$  开始，到 Episode 结束，实际获得的所有奖励的总和。就像一局游戏的总得分。

## 蒙特卡洛价值评估：步骤详解

### 蒙特卡洛价值评估的流程：

1. 从状态  $S$  开始，让智能体与环境交互，完成一个 Episode。
2. 记录这个 Episode 中从状态  $S$  开始到结束的 Return (回报)  $G_t$ 。
3. 重复步骤 1 和 2 很多次 (例如，玩很多局游戏)。
4. 计算所有 Episode 的 Return 的平均值。
5. 这个平均值就是状态  $S$  的价值  $V(S)$  的蒙特卡洛估计。

蒙特卡洛价值评估的核心就是：多次试验，取平均值。 试验次数越多，估计结果越准确。



## 例子：掷骰子游戏的价值评估

**情景描述：**一个简单的掷骰子游戏：每次投掷一个六面骰子，如果点数大于3(4,5,6)，奖励+1;否则(1,2,3)，奖励-1。我们想评估“初始状态”的价值。

**表格：**模拟多次游戏(Episodes)的表格，记录每次游戏的 Return:

| Episode | 游戏过程(简化)     | Return(回报)    |
|---------|--------------|---------------|
| 1       | 6->2->5 (结束) | +1 -1 +1 = +1 |
| 2       | 4->1->3 (结束) | +1 -1 -1 = -1 |
| 3       | 5->6->4 (结束) | +1 +1 +1 = +3 |
| ...     | ...          | ...           |
| 平均值     | ...          | (计算平均值)       |

通过多次模拟游戏，计算平均 Return，就可以估计出“初始状态”的价值。

## 蒙特卡洛方法的优点与局限性

### 优点:

- **简单易懂, 原理直观:** 核心思想就是 “多次实验, 取平均”, 容易理解和实现。
- **无需环境模型 (Model-Free):** 不需要预先知道环境的详细规则, 只需与环境交互采样数据即可。

### 局限性:

- **高方差:** 每次 Episode 的结果随机性较大, 可能导致价值估计的波动性较大。
- **效率较低:** 需要等待 Episode 结束后才能更新价值估计, 学习速度可能较慢。
- **不适用于持续性任务:** 蒙特卡洛方法需要完整的 Episode, 对于没有明确终止状态的持续性任务不太适用。

## 蒙特卡洛方法的总结

蒙特卡洛方法是一种重要的价值评估工具，它通过多次试验和平均的方式，帮助我们估计强化学习中状态的价值。虽然有一定局限性，但其简单性和无需模型的特点，使其在强化学习领域仍然被广泛应用。

# Part 2



## Actor-Critic 模型



# Actor-Critic 模型




北京邮电大学  
Beijing University of Posts and Telecommunications

Actor-Critic 模型：融合“策略”与“价值”

Actor-Critic 模型是一种更高级的强化学习方法，它同时学习两种东西：

- **策略(Policy)**：由**Actor(演员)**负责学习，策略决定了智能体在不同状态下应该采取什么**动作**。
- **价值函数(Value Function)**：由**Critic(评论家)**负责学习，价值函数评估了在给定状态(或状态-动作对)下的**价值**。



# Actor-Critic 模型




北京邮电大学  
Beijing University of Posts and Telecommunications

## Actor(演员): 策略学习与动作输出

**Actor(演员)**的核心任务是**学习和优化策略** (Policy)。策略就像是Actor的“剧本”或“行动指南”，告诉Actor在不同“状态”下应该“表演”什么“动作”。

Actor 通常由一个**神经网络(策略网络)**来表示，输入是**状态** (State)，输出是**动作** (Action)(或动作的概率分布)。

Actor的目标是学习**最优策略**，使得智能体能够获得最大累积奖励。



# Actor-Critic 模型



北京邮电大学  
Beijing University of Posts and Telecommunications


## Critic(评论家):价值评估与策略指导

**Critic(评论家)**的核心任务是**学习价值函数** (Value Function), 并**评估 Actor 的策略好不好**。

Critic就像是“专业的评论家”或“教练”, 对Actor的“表演”进行“打分”和“指导”。

Critic 通常也由一个 **神经网络 (价值网络)**来表示, 输入可以是**状态** (State)(或状态-动作对 (State-Action Pair)), 输出是**价值评估值**。

Critic 的评估结果, 可以用来**指导Actor 改进策略**, 让 Actor知道哪些动作是好的, 哪些动作是坏的, 从而朝着更好的方向学习。



# Actor-Critic 模型




北京邮电大学  
Beijing University of Posts and Telecommunications

## Actor-Critic 模型框架：协同工作

Actor 和 Critic在强化学习过程中**紧密协作，互相促进**：

1. Actor根据当前**策略**，在状态 $S$ 下选择动作  $A$ 。
2. 智能体执行动作 $A$ ，与环境交互，获得奖励 $R$ 和下一个状态 $S'$ 。
3. Critic接收**状态 $S$ ，动作 $A$ ，奖励 $R$ ，下一个状态 $S'$** 等信息，评估当前状态-动作对  $(S, A)$  的**价值**。
4. Actor根据**Critic的价值评估结果**，**调整和改进自己的策略**，使其输出的动作能够获得更高的价值。
5. Critic也**不断学习和更新价值函数**，使其更准确地评估价值。这个过程循环进行，直到Actor 和Critic都学到最优策略和价值函数。





## DDPG: 强大的连续动作控制算法

**DDPG(Deep Deterministic Policy Gradient)** 是 Actor-Critic模型的一种**非常流行且强大**的变体, 特别擅长解决**连续动作控制**问题。例如, 控制机器人的关节角度、汽车的方向盘转角等。


### DDPG的特点:

- Deep(深度)
- Deterministic Policy(确定性策略)
- Policy Gradient(策略梯度)

## DDPG的关键组成部分


DDPG为了更有效地训练深度神经网络，并解决连续动作控制问题，引入了一些关键技术组件。

- **Actor 网络( $\mu$ ):**输出确定性动作。
- **Critic 网络( $Q$ ):**评估状态-动作对的 $Q$ 值。
- **目标网络 (Target Networks- $\mu'$ ,  $Q'$ ):**Actor目标网络和Critic目标网络，用于稳定训练。
- **经验回放缓冲区 (Replay Buffer):**存储经验数据，打破数据相关性，提高训练稳定性。



## DDPG的训练流程(核心步骤)

1. Actor根据当前策略, 选择**动作**与环境交互, 收集**经验数据**(状态,动作,奖励,下一状态)。
2. 将经验数据存储在**经验回放缓冲区 (Replay Buffer)**。
3. 从Replay Buffer中**随机采样**一批数据。
4. 使用Critic网络评估动作价值。
5. 使用**策略梯度**更新Actor网络, 使其策略朝着更有利的方向改进。
6. 更新Critic网络, 使其更准确地评估动作价值。
7. **软更新(Soft Update)**目标网络参数(保持训练稳定性)。
8. 重复步骤1-7, 直到模型收敛。



## DDPG 的应用场景:更广泛的应用



**机器人控制:**复杂机械臂操作, 人形机器人运动, 四足机器人跳跃。



**游戏 AI:** 赛车游戏, 飞行模拟游戏, 3D 动作游戏。



**自动驾驶:**车辆精准控制, 复杂交通场景处理。



**工业控制:**自动化生产线, 智能制造系统。



**金融交易:** 量化交易, 资产配置。

# Actor-Critic 模型总结



北京邮电大学  
Beijing University of Posts and Telecommunications

## Actor-Critic 模型的优势

- **结合 Policy-based 和 Value-based 方法的优点：**既能学习策略，又能进行价值评估，学习效率更高，更稳定。
- **适用于连续动作空间和离散动作空间：**通用性更强。
- Critic 的价值评估可以降低策略梯度方法的方差，提高学习稳定性。

# Actor-Critic 模型总结



北京邮电大学  
Beijing University of Posts and Telecommunications

## Actor-Critic 模型的挑战

- **训练难度相对较高：** Actor 和 Critic 需要协同学习，参数调整比较复杂。
- **对 Critic 的依赖性：** Actor 的策略改进依赖于 Critic 的价值评估，如果 Critic 评估不准确，会影响 Actor 的学习效果。
- **仍然可能存在样本效率问题：** 对于复杂任务，可能仍然需要大量的样本数据进行训练。

# Actor-Critic 模型总结



北京邮电大学  
Beijing University of Posts and Telecommunications

## Actor-Critic 模型的发展趋势

Actor-Critic 模型一直是强化学习领域的研究热点，未来的发展趋势包括：

- **更高效的探索策略：**提高智能体探索环境的能力，更快地发现有价值的经验。
- **更稳定的训练方法：**解决 Actor-Critic 模型训练不稳定的问题，例如改进目标网络更新机制，使用更先进的优化算法。
- **与其他技术的融合：**例如，与模仿学习、元学习、注意力机制等技术的结合，提升 Actor-Critic 模型的性能和泛化能力。

# Actor-Critic 模型总结



北京邮电大学  
Beijing University of Posts and Telecommunications

## Actor-Critic 模型的总结

Actor-Critic 模型是一种强大且灵活的强化学习框架，它通过 Actor 和 Critic 的协同学习，能够有效地解决复杂决策问题，尤其在连续动作控制领域表现出色。

DDPG 是 Actor-Critic 模型中最具代表性和应用价值的算法之一。



# Part 3




案例:AlphaGo



# 案例:AlphaGo


## AlphaGo:围棋 AI 的突破(里程碑意义)

AlphaGo 的成功，是人工智能发展史上一个里程碑式的事件。它不仅在围棋这个被认为是“人类智慧最后堡垒”的领域超越了人类顶尖棋手，更重要的是，它展示了强化学习和深度学习结合的强大力量，为人工智能的未来发展指明了方向。



# 案例:AlphaGo

## AlphaGo 的核心技术框架



AlphaGo 的核心技术框架可以概括为: 深度强化学习(Depth Reinforcement Learning) 和 蒙特卡洛树搜索 (Monte carlo Tree search,MCTS)。

这两项关键技术相互配合, 共同支撑了AlphaGo的强大棋力。 AlphaGo 的训练方式是自我对弈 (Self-Play), 通过与自身不断对弈, 产生大量的训练数据, 并持续提升棋力。


# 案例:AlphaGo



北京邮电大学  
Beijing University of Posts and Telecommunications

## 蒙特卡洛树搜索(MCTS):决策规划的关键

蒙特卡洛树搜索 (MCTS)是 AlphaGo 决策规划的核心算法，它让AlphaGo 在每一步棋的决策时，能够进行“预测未来”和“策略搜索”，从而选择最优的落子。



## 蒙特卡洛树搜索(MCTS):决策规划的关键

### MCTS 的工作流程主要包含四个阶段:

- **选择(Selection):** 从根节点出发, 依据某种策略 (如UCT) 选择最有潜力的子节点, 直到到达一个可扩展的节点。目标是平衡探索与利用, 确保搜索效率。
- **扩展(Expansion):** 当选择的节点未被完全探索时, 扩展该节点, 添加一个或多个子节点, 代表可能的下一步动作。扩展增加了搜索树的广度。
- **模拟 (Simulation):** 从扩展的节点开始, 随机模拟游戏直到结束, 得出胜负结果。模拟阶段通过随机性快速评估节点的潜在价值。
- **反向传播(Backpropagation):** 将模拟结果从扩展节点回溯到根节点, 更新路径上所有节点的统计信息 (如胜率、访问次数)。这帮助后续选择阶段做出更优决策。

通过不断循环这四个阶段, MCTS 可以逐步构建出一棵搜索树, 帮助 AlphaGo 找到最佳的行动方案。

## 深度神经网络:策略网络与价值网络(关键组件)

深度神经网络(Deep Neural Networks)在 AlphaGo 中也扮演着至关重要的角色。

AlphaGo 使用了两种深度神经网络:

- **策略网络(Policy Network):** 预测在当前局面下, 下一步棋的最佳落子概率分布。策略网络帮助 MCTS 在搜索时, 更有效地选择更有希望的搜索方向。
- **价值网络 (Value Network):** 评估当前围棋局面的胜率。价值网络帮助 MCTS 在搜索树的叶子节点进行快速评估, 减少模拟的深度和计算量。

策略网络和价值网络的训练, 都是基于强化学习的方法, 通过大量自我对弈数据进行训练和优化。它们为 MCTS 提供了强大的预测能力和评估能力, 使得AlphaGo能够进行高效的决策规划。



# 案例:AlphaGo



北京邮电大学  
Beijing University of Posts and Telecommunications

## AlphaGo 的精彩棋局与决策分析

AlphaGo 的决策思路主要基于蒙特卡洛树搜索 (MCTS) 和神经网络 (策略网络与价值网络) 的结合, 展现了超越人类直觉和经验的强大智能。

“神之一手”



- **蒙特卡洛树搜索 (MCTS)** : MCTS 通过模拟大量可能的棋局路径来探索多种走法。它从当前局面出发, 逐步扩展搜索树, 评估每一步的潜在结果。在搜索过程中, MCTS 会平衡“探索”和“利用” : 既尝试新的走法, 也优先选择表现较好的走法。
- **策略网络** : 策略网络用于预测每一步的落子概率, 帮助 MCTS 缩小搜索范围, 集中在高概率的走法上。它通过学习大量人类棋谱, 能够模仿人类棋手的直觉, 提供合理的落子建议。
- **价值网络** : 价值网络评估当前局面的胜率, 帮助 MCTS 判断某一步的长期收益。它通过自我对弈训练, 能够预测棋局的最终结果, 减少对大量模拟的依赖。

# 案例:AlphaGo

## AlphaGo 的意义与深远影响 (人工智能的新时代)

AlphaGo 的成功，不仅仅是 AI 在围棋领域的胜利，更开启了人工智能发展的新时代。它证明了深度强化学习是一种非常有效且通用的人工智能技术，可以应用于解决各种复杂决策问题。AlphaGo的成功，极大地激发了人们对人工智能的研究热情和应用探索，推动了人工智能技术在各个领域的快速发展。



- **蒙特卡洛方法:** 多次试验, 平均评估价值, 无需模型, 但方差较高。
- **Actor-Critic 模型:** 结合策略学习 (Actor) 和价值评估 (Critic), DDPG 是一种强大的 Actor-Critic 算法, 适用于连续动作控制。
- **AlphaGo 案例:** 深度强化学习+ MCTS 的成功应用, 围棋AI 的里程碑, 展现了 AI 在复杂决策问题上的巨大潜力。

# 未来展望



北京邮电大学  
Beijing University of Posts and Telecommunications

01

## 通用人工智能(AGI)

探索更通用的智能体，能够解决更广泛的任务。

02

## 机器人技术

更智能的机器人，能够自主完成复杂任务。

03

## 自动驾驶

更安全、更可靠的自动驾驶系统。

04

## 智能医疗

辅助诊断，药物研发，个性化治疗。

05

## 智能金融

量化交易，风险管理，智能投顾。

06

## 智能教育

个性化学习，智能辅导。

“ 感谢您的观看 ”

