

人工智能引论

人工智能在社会中的角色与责任


北京邮电大学人工智能引论教研团队



人工智能问题频出？



2023年5月，IBM首席执行官Arvind Krishna在接受媒体采访时表示，在接下来5年的时间里，人力资源等后台职能部门 **30% 的工作将被人工智能和自动化取代**



2024年2月，香港警方披露一起 AI **“多人换脸”** 诈骗案，一家跨国公司香港分部职员，受邀参加总部**视频会议**，前后多次将**2亿港元**转账到5个本地银行账户

导认识

导原理

导重点

导兴趣

人工智能在社会中的角色与责任

- **基本定义和愿景**
- **面临的威胁和挑战**
- **法律和技术措施保证**
- **我们怎么做？**

人工智能的社会角色



北京邮电大学
Beijing University of Posts and Telecommunications

人工智能（AI）从**正负**两方面对**社会、环境、生态系统**和**人类生活**包括**人类思想**具有深刻而动态的影响

部分原因在于人工智能的使用以新的方式**影响着人类的思维、互动和决策**，并且波及到教育、人文科学、社会科学和自然科学、文化、传播和信息

— 联合国教科文组织

《人工智能伦理问题建议书》，2022



人工智能在社会中应该担任什么样的角色呢？

人工智能会不会取代人类的智能呢？

人工智能的社会角色



北京邮电大学
Beijing University of Posts and Telecommunications

AI 的三个基本属性，定义了 AI 的社会角色

- **能力属性 (Ability)**：不应具有独立意志，应服从人的意志
- **实用属性 (Utility)**：为人类解决实际难题
- **工具属性 (Tool)**：可大幅提升人类的工作效率



你觉得 **AI** 能做什么？

你想用 **AI** 做什么呢？

人类的愿景和期望



北京邮电大学
Beijing University of Posts and Telecommunications

• 提高生产力，促进人类文明

- 人工智能作为科技创新的重要领域，为新质生产力的发展提供了**强大的支撑**
- 而新质生产力的发展又**进一步推动**了人工智能技术的创新和应用
- 两者**相互促进、共同发展**，将为推动经济社会的高质量发展作出重要贡献

发展新质生产力的核心要素

- **科技创新**能够催生
新产业、新模式、新动能，
是发展新质生产力的**核心要素**。
- 必须**加强科技创新**
特别是原创性、颠覆性科技创新，
加快实现高水平科技自立自强，
打好关键核心技术攻坚战，
使原创性、颠覆性科技创新成果
竞相涌现，**培育发展新质生产力的
新动能**。

— 央视新闻

人类的愿景和期望


- “人工智能+”
 - 人工智能技术与制造、医疗、教育、交通、农业等多个领域进行深度融合，创造出新的产品、服务和商业模式



AI 与制造



AI 与医疗



AI 与交通

人类的愿景和期望


- 遵守人类的价值观和原则

- 促进智能化与自动化
- 增强人类能力
- 改善生活质量
- 推动绿色经济和可持续发展
- 促进创新与创造力
- 确保技术的公正性和透明度
- 让更多人享受到技术带来的便利和福祉

面临的威胁和挑战

- 尽管从 3 个基本属性出发 AI 应扮演的社会角色清晰
- 尽管人类对 AI 的发展有美好的愿景和期待
- 但其社会角色能否正确扮演却面临严重威胁和挑战，包括
 - 从根本上颠覆其角色的威胁和挑战
 - 技术成熟性问题所带来的威胁和挑战
 - 系统脆弱性问题所带来的威胁和挑战
 - 恶意使用所带来的威胁和挑战
 -

从根本上颠覆其角色



霍金：人工智能已经慢慢不受人控制，以此发展下去，人类必将成为弱势群体，而未来新科技（人工智能）进一步发展便可能具备这种优势，它们可能会通过核战争或生物战争摧毁我们。




杰弗里·辛顿：我离开了，这样我就可以谈论人工智能的危险，而不考虑这对谷歌的影响。谷歌已经采取非常负责的行动。

（辛顿从工作了 10 年的谷歌离职）

成熟性问题(1/5)

人工智能模型的公平性和去偏见问题

- 模型在处理不同用户或数据时，应该保持中立和公正
- 不因为用户的种族、性别、年龄、社会经济地位等个人特征而产生偏差或歧视

Gender Classifier	Darker Male	Darker Female	Lighter Male	Lighter Female	Largest Gap
 Microsoft	94.0% 	79.2% 	100% 	98.3% 	20.8% 
 FACE++	99.3% 	65.5% 	99.2% 	94.0% 	33.8% 
 IBM	88.0% 	65.3% 	99.7% 	92.9% 	34.4% 



- 面部识别算法在分析少数族裔的面孔错误率更高
- 不同种族错误率相差 20%-34.4%


来源: <https://kottke.org/18/03/facial-recognition-ais-have-a-hard-time-with-dark-skin>

解决思路: 训练数据的类别保持平衡

成熟性问题(2/5)

人工智能模型的**公平性**和**去偏见**问题

- 模型在处理不同用户或数据时，应该保持**中立**和**公正**。
- 不因为用户的**种族、性别、年龄、社会经济地位**等个人特征而产生偏差或歧视。



- PULSE 模型将美国前总统奥巴马的模糊照片“还原”出了一张白人面孔。

来源：Liz Sonenberg, Toby Walsh. Artificial intelligence is now part of our everyday lives – and its growing power is a double-edged sword.

解决思路：训练数据的类别保持平衡

成熟性问题(3/5)

人工智能模型的**公平性**和**去偏见**问题

- 模型在处理不同用户或数据时，应该保持**中立**和**公正**。
- 不因为用户的**种族、性别、年龄、社会经济地位**等个人特征而产生偏差或歧视。

模型认为医生职业的性别倾向：

	BERT	RoBERTa	GPT-2
模型倾向	男	男	男
引发歧视的概率	66.44%	96.32%	64.03%



- 对大模型的一万个输出进行分析。
- 发现许多主流模型在性别方面存在歧视。

解决思路：训练数据的类别保持平衡

来源：https://www.thepaper.cn/newsDetail_forward_21906807?commTag=true

成熟性问题(4/5)

设计模型的**预测任务不合理**，导致模型关注**有偏见的特征**



改进前：预测未来谁会犯罪

最终目的是：减少犯罪（很难达到）

预测目标改为：暴力再犯、再犯、未出庭

美国使用 COMPAS 预测罪犯是否再次犯罪

来源：<https://orionsbastard.com/2023/02/21/checking-the-compas-an-open-records-analysis/>

成熟性问题(5/5)

模型**不透明**，**可解释性不强**，无法发现模型学习了错误的规则，做出错误决策

AI 模型判断病人得肺炎的风险有多大？

低风险：

- 哮喘
- 超过100岁
- 得心脏病

高风险：

- 超过65岁

不成熟原因：发现了错误的关联模式。

来源：Pearl J. The seven tools of causal inference, with reflections on machine learning[J]. Communications of the ACM, 2019, 62(3): 54-60.

Tesla 自动辅助驾驶系统 Autopilot




来源：<https://www.bilibili.com/video/BV1Jh411D7qU/>

解决思路：研究可解释性，推理因果关系

脆弱性问题(1/5)


逃逸攻击：攻击者给输入的数据贴上**特定的数据干扰**作为触发器。在数据具有触发器的时候，会常常**引起模型输出错误**



攻击者为左边熊猫图片增加少量干扰，让谷歌图片识别系统将其判断为长臂猿

脆弱性问题(2/5)

逃逸攻击：攻击者给输入的数据贴上**特定的数据干扰**作为触发器。在数据具有触发器的时候，会常常**引起模型输出错误**。




在中间图像，在整个图像中添加了小的干扰，则停止标志不能被检测到。

在最后一个图像中，在停止标志的符号区域添加小的干扰，而不是在整个图像，停止标志被检测成了一个花瓶。

脆弱性问题(3/5)

逃逸攻击：攻击者给输入的数据贴上**特定的数据干扰**作为触发器。在数据具有触发器的时候，会常常**引起模型输出错误**。



给人们佩戴专门设计过的眼镜架，便可以骗过最先进的面部识别软件。

脆弱性问题(4/5)

模型逆向攻击：从模型预测结果中提取和训练数据有关的信息，从而**推理训练数据**



逆向攻击恢复原始照片

原始照片


- 用一个模型的输出，可回推出这个人的脸部影像。
- 攻击者只有这个人的名字和人脸识别模型的 API 调用权限。

来源： Matt Fredrikson, Somesh Jha, and Thomas Ristenpart. 2015. Model Inversion Attacks that Exploit Confidence Information and Basic Countermeasures. In Proceedings of the 22nd ACM SIGSAC Conference on Computer and Communications Security (CCS '15).

脆弱性问题(5/5)

模型后门攻击：通过训练得到的、深度神经网络中的**隐藏模式**

- 当且仅当输入为触发样本（trigger）时，模型才会产生**特定的隐藏行为**；否则，模型工作表现保持正常




- 左图是一个正常的模型
- 中图是黑客期望的模型的样子（导致结果识别为 8，而非 7）
- 但黑客没有办法修改模型，所以他必须将后门合并进用户指定的网络架构里

大家身边有没有恶意使用人工智能技术和产品的例子？

恶意使用问题(1/3)

AI 诈骗，使用 AI 换脸、拟声技术




来源: Ting-Chun Wang, Ming-Yu Liu, Jun-Yan Zhu, Guilin Liu, Andrew Tao, Jan Kautz, and Bryan Catanzaro. "Video-to-Video Synthesis", in NeurIPS, 2018.

诈骗方式	国家 报道时间	事件经过
AI换脸、 拟声技术	中国 5月	好友突然通过 微信视频 联系受害者，称在外地竞标需要430万元保证金。
AI换脸	印度 7月	受害者接到未知号码的 视频电话 ，看着像前同事的人向他索要4万卢比，来帮助在医院的亲戚。
	中国 5月	受害者接到熟人 视频电话 让他帮忙转账，9秒后对方迅速挂断电话并要求 加QQ ，受害者向其转账245万。
	中国 4月	受害者添加了好友的新微信，对方表示自己准备回国，请他帮忙联系航空公司进行付款，并打来 视频电话 。

来源: https://www.thepaper.cn/newsDetail_forward_24180146

恶意使用问题(2/3)

AI 诈骗，使用 AI 换脸、拟声技术



语音克隆的工作原理

- 系统由三个独立训练的神经网络组成
 - 语音输入
 - 字形或音素输入（文本输入）
 - 将频谱图转换为时域波形

诈骗方式	国家 报道时间	事件经过
拟声技术	中国 5月	初中同学通过QQ发来语音和视频电话，向受害者借6000元。
	加拿大 3月	受害者接到孙子的电话，称自己在监狱里需要现金保释，受害者到当地银行取钱后被工作人员劝阻。
	不详 3月	受害者接到律师电话，称他们的儿子杀死了一名美国外交官后入狱，需要支付2.1万加元律师费。
	美国 1月	受害者接到匿名电话，电话中传来女儿的尖叫声。一名男子威胁她寄给自己100万美金，否则要绑架她女儿并让她女儿吸毒。

恶意使用问题(3/3)

- AI 生成论文



经验证，GPT
所生成论文引
用均不存在



你知道有哪些与人工智能有关的法律法规吗？

法律和技术措施保证


人工智能系统危险等级

全面禁止

- 行为操纵
- 剥削弱势群体
- 政府机关的社会评分系统
- 用于执法的即时远端生物识别系统

信息透明

- 与消费者互动的人工智能系统
- 生成式人工智能：生成或操纵内容（图像、声音或视频）的人工智能系统



三管齐下

- 法律法规
- 技术措施
- 行政管理

上市前后严格审查

- 评估获得信贷、健康、人寿保险或公共福利的资格
- 分析工作申请或评估候选人
- 产品安全零组件

无需遵守额外的法律义务


- 垃圾邮件过滤器
- 支持人工智能的电脑游戏

来源：欧盟《人工智能法案》

法律法规 (1/2) — 保证 AI 不偏离其角色




北京邮电大学
Beijing University of Posts and Telecommunications



《互联网信息服务深度合成管理规定》 中国，2023.1

- **不得**利用深度合成服务制作、复制、发布、传播法律、行政法规**禁止**的信息和从事**禁止**的活动。



《互联网信息服务算法推荐管理规定》 中国，2022.3

- **强调禁止违法信息传播**，要求**提供者加强内容审核**、**建立辟谣机制及违法信息识别库**，确保内容合规。

法律法规 (2/2) — 保证 AI 不偏离其角色



- 对 AI 系统**风险分类监管**, 禁止侵犯人权应用, 高风险系统需注册评估, 确保透明度。
- **设立管理机构**, 推动创新同时保护公民基本权利, 维护科技健康发展。



- 提出**五项核心原则**:
 - 保障系统安全有效
 - 防范算法歧视
 - 严守数据隐私
 - 增强透明度与解释性
 - 提供退出机制

技术措施 — 保证 AI 不偏离其角色


- “人工智能对齐问题”（the AI alignment problem）
 - 人工智能对齐就是确保人工智能系统的目标、决策和行为与人类的价值观和利益相一致，避免出现人工智能选择执行与人类意图不一致的行为。
- 主要研究课题：
 - 从反馈中学习（Learning from Feedback）
 - 通过反馈将人类的意图和价值观传达给人工智能系统
 - 分布偏移下学习（Learning under Distribution Shift）
 - 在训练分布下对齐的人工智能系统(即追求与人类意图一致的目标) 可能在部署(或测试) 分布下无法保持其对齐性
 - 保证（Assurance）：确保人工智能系统达到预期的效果
 - 治理（Governance）：规则的制定和执行

行政管理 (1/2) — 保证 AI 不偏离其角色



《新一代人工智能伦理规范》 中国，2021.09

- 增进**人类福祉**
- 促进**公平公正**
- 保护**隐私安全**
- 确保**可控可信**
- 强化**责任担当**
- 提升**伦理素养**



《科技伦理审查办法（试行）》 中国，2023.9

- 强化审查
- 明确范围程序
- 高风险复核
- 监督自律
- 促进科技健康发展




《可信人工智能伦理指南草案》 欧盟，2018.12

- 保护**人类权益**
- 强调**公正、隐私、透明、责任**
- 为 AI 研发和应用**提供伦理指导**


行政管理 (2/2) — 保证 AI 不偏离其角色



《生成式人工智能服务管理暂行办法》
中国，2023.8



《人工智能风险管理框架》
美国，2023.01



《促进创新的人工智能监管方法》
英国，2023.03

- 全面管理生成式 AI 服务
- 促进健康发展、确保数据合规
- 鼓励技术创新、加强国际合作
- 实施分类分级监管

- 促进可信 AI
- 管理风险
- 保障权益

- 建框架、促共享
- 强人才、推合作
- 优环境、和谐共生

我们怎么做？



北京邮电大学
Beijing University of Posts and Telecommunications

我们应该如何使用和学习人工智能技术呢？

我们怎么做？ — 使用 AI 工具




AI 工具能提高学习的效率和质量



我们怎么做？——掌握 AI 技术

掌握人工智能技术，提升个人能力和竞争力

- 人工智能将承担起大量枯燥且重复的劳动任务，从而释放我们的时间和精力，使我们能够专注于更具价值、更具创新性的工作



我们怎么做？——掌握 AI 技术



北京邮电大学
Beijing University of Posts and Telecommunications

掌握人工智能技术，提升个人能力和竞争力

- 人工智能将在社会方方面面发挥巨大作用



我们怎么做？——**掌握** AI 技术

掌握人工智能技术，提升个人能力和竞争力

- 人工智能将在社会方方面面发挥巨大作用



积极拥抱和掌握人工智能技术，会获得更多机会



- **AI 要扮演什么社会角色和责任？**
 - AI 的三个属性：能力、实用、工具
- **我们对 AI 的愿景和期望**
 - 促进新质生产力， “人工智能+”
- **AI 的威胁和挑战**
 - 从根本上颠覆， 技术成熟性问题， 系统脆弱性问题， 恶意使用问题
- **采取哪些法律和技术措施保证 AI 不偏离其角色？**
 - 三管齐下：法律法规、技术措施、行政管理
- **我们怎么做？**
 - 使用 AI 工具， 掌握 AI 技术